Государственное бюджетное профессиональное
образовательное учреждение Московской области
«Физико-технический колледж»

Отчёт по кейсу «Самолёт»:

Работу выполнил:
Студент группы № ИСП-21
Бухаров Егор

Долгопрудный, 2024

Введение

В данном отчёте рассматриваются выводы, полученные с аналитической работы над данными в области «Квартиры в Московской области, Новой Москве и Москве».

Цель

Собрать данные и произвести аналитическую работу над ними для будущих работ, например, создание модели на основе выводов.

Задачи

- Используя открытые источники собрать список данных.
- На основе полученной информации произвести удаление ненужных данных, дополнение необходимых, выявление аномалий и их блокировка.
- Визуализация данных при помощи, как минимум, двух инструментов для подобных задач. Нахождение взаимосвязей между данными или их полное отсутствие, усреднённых показателей для уверенного отчёта.

Основная часть

Для выполнения основной задачи, существует небольшой выбор источников, откуда собирать данные, мною был выбрать интернет-ресурс «Циан». При помощи скриптов, написанных на языке Python и библиотеке CianParser было получено свыше десяти тысяч объявлений в нужных регионах.

К следующей задаче подходит такое начало, как соединение собранных данных в одну таблицу при помощи написанной функции с библиотекой Pandas.

После сбора всей информации воедино и уборки дубликатов, нужно узнать, какого типа наши данные (рис.1), так как отталкиваясь от типа данных, мы будем применять разные методы к их сортировке.

Теперь мы убираем -1 как базовое не собранное значение и смотрим, какие данные у нас смогли собраться(рис.2) при помощи библиотеки missingno. Как мы можем увидеть, object_type и heating_type практически нигде не указываются, значит мы вынуждены их удалить, так как строить анализ будет невозможно.

Далее отсеиваем ненужные данные и форматируем некоторые столбцы, чтобы их было легче анализировать с помощью сторонних инструментов(рис.3). После выполнения объёмной чистки данных, нужно проверить их состояние – смотрим внутрь файла и бегло проверяем на аномалии, в случае их отсутствия приступаем к кодовой проверке данных(рис.4-7).

После полной очистки данных вручную и программно можем приступать к сбору графиков/аналитической работе при помощи библиотеки matplotlib для вывода графических изображений. Например будет 4 графика:

1. Цена за м^2 по городам.
2. Цена за м^2 в зависимости от материала, используемого при постройке здания.
3. Количество объявлений по городам.
4. Количество объявлений по годам постройки здания.

Для первых и последних двух графиков будем использовать один метод подсчёта данных.

Первый метод – отбор цены за квадратный метр по трафаретному коду и запись в csv-файл(рис.8).

Второй метод – использование встроенной функции .value_counts() и запись в csv-файл для дальнейшей обработки(рис.9).

В итоге получаем графики(рис.10), на основе которых уже можно проводить анализ, но мы перейдём к составлению графиков на Power BI.

Power BI – максимально удобный инструмент для составления графиков и аналитики данных.

Для первого графика мы выбираем данные price, меняем сумму на «среднее» и включаем их в график, на другую ось ставим «year_of_construction». Выбираем тип графика и получается примерный график со средней ценой квартиры, в зависимости от года его постройки(рис.11).

Второй график будет содержать в себе среднюю цену квартиры, в зависимости от материала здания(рис.12), просто вместо года постройки ставим тип материала. Добавлю к этим данным среднюю цену по виду отделки(рис.13).

Аналитика данных

Благодаря выведенным графикам, можно сделать выводы, что цена в основном зависит от типа отделки, материала дома, города. От года постройки зданий зависит лишь их количество на рынке и количество комнат во время СССР, а на цену никак не влияет.

Заключение

В результате аналитической работы были собраны, отсортированы, почищены данные, простроены удобные для анализа графики, благодаря которым получилось выявить не маловажные критерии в оценивании стоимости недвижимости в Московской Области, Москве и Новой Москве. Основными факторами, оказывающими влияние на стоимость, выявились тип отделки, материала здания и расположение. Полученные данные могут быть использованы для дальнейшей разработки прогностических моделей.

Открываем наши драгоценные данные

```
df = pd.read_csv('11K.csv')
```

Смотрим форму и колонки нашых данных

```
print(df.dtypes)
df.shape
```

```
author                  object
author_type             object
url                     object
location                object
deal_type               object
accommodation_type      object
floor                  float64
floors_count           float64
rooms_count            float64
total_meters            object
price                  float64
year_of_construction    object
object_type            float64
house_material_type     object
heating_type           float64
finish_type             object
living_meters           object
kitchen_meters          object
phone                  float64
district                object
street                  object
house_number            object
underground             object
residential_complex     object
dtype: object

(10582, 24)
```

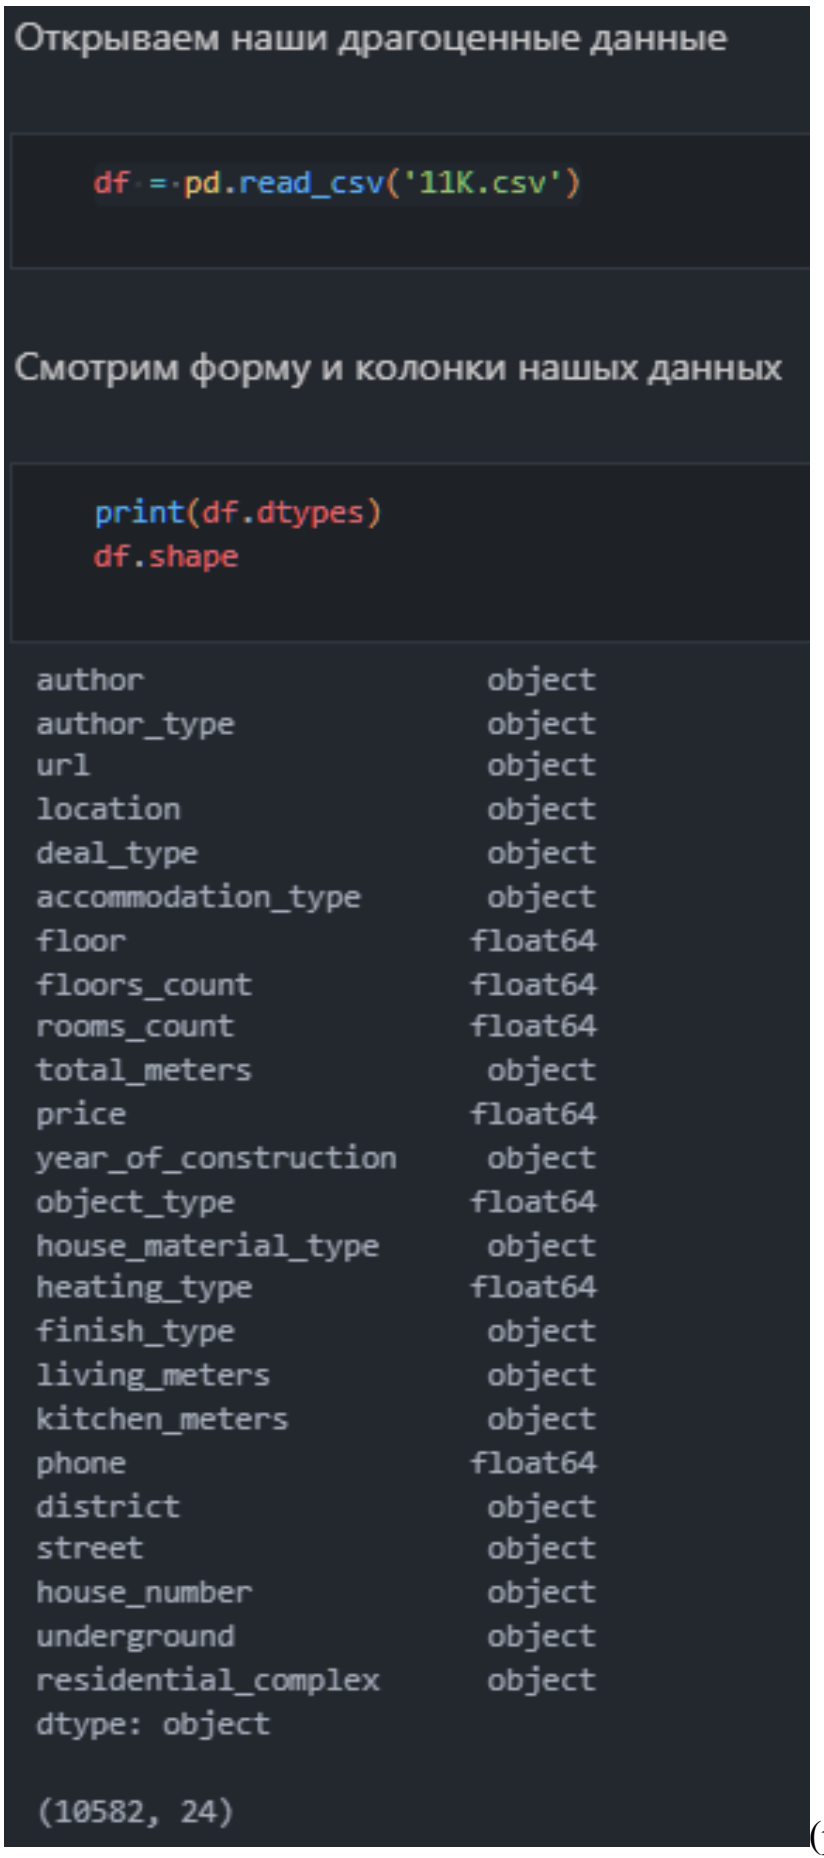

(рис.1)

Чистим от отрицательных значений

```
df = df.replace(-1,np.nan) # Убираем все виды плохих или не собранных данных
df = df.replace("-1",np.nan) # Убираем все виды плохих или не собранных данных
df = df.replace(-1.0,np.nan) # Убираем все виды плохих или не собранных данных
df = df.replace("-1.0",np.nan) # Убираем все виды плохих или не собранных данных
df = df.replace("���",0) # Убираем все виды плохих или не собранных данных
df.to_csv("half_11K.csv", index=False) # Тут запись в отдельный файл, дабы поэтапно отслеживать, на каком моменте появляются аномальные действия
# Ещё мы заходим в сохранённый файл и меняем ��? на 0, дабы избежать ошибок (сделал отдельно)
```

Чекаем корректность данных

```
msn.bar(df, figsize=(7,4), fontsize=10, color=(1, 0.75, 0.8))
```

```
<Axes: >
```

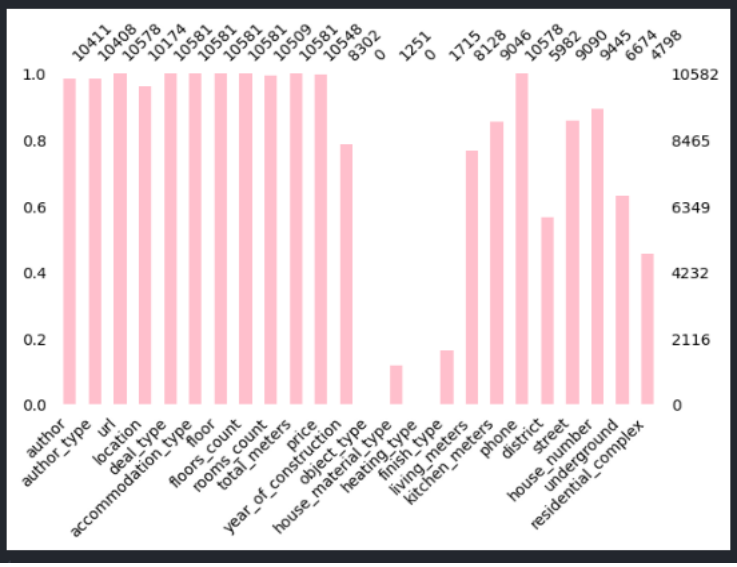

(рис.2)

```
df = pd.read_csv('half_11K.csv')
list = ["Напишите автору","Залоговая недвижимость","Аукцион","Позвоните автору","Подписаться на дом"]
for obj in list: df = df.replace(obj, np.nan) # Стираем
list1 = ["total_meters","living_meters","kitchen_meters"] # Данные, которые мы очистим от метров в ква
del df['author'] # Не надо
del df['author_type'] # Не надо
del df['accommodation_type'] # Это тип хаты
del df['deal_type'] # Тип сделки, у нас только продажа
del df['residential_complex'] # Много пропущено и не особо надо
del df['heating_type'] # Подогрев, нигде не указан
del df['object_type'] # Чет ваще не нужная штука
del df['phone'] # звонить для аналитики не нужно
list = ["price","year_of_construction","floor","floors_count","rooms_count"] # Создаём лист с данными,
for obj in list:
    df[obj] = df[obj].fillna(0) # Заполняем пустоты нулями
    df[obj] = df[obj].astype(int) # Оформляем INT для чистоты разума
for obj in list1: df[obj] = pd.to_numeric(
    df[obj].str.replace(',', '.').apply(lambda x: x[:-3] if pd.notna(x) else np.nan),
    errors='coerce'
    ).astype('float64')
df.to_csv("tret'_11K.csv", index=False) # Различия между cleaned_11K и tret'_11K - это ручной отброс п
```

(рис.3)

```python
# Связи числовых данных
plt.figure(figsize=(8,4))
sns.heatmap(df.corr(numeric_only=True), cmap='crest', annot=True, vmin=-1, vmax=1)
plt.xticks(rotation=30, ha="right")
plt.show()
```

✓ 0.2s

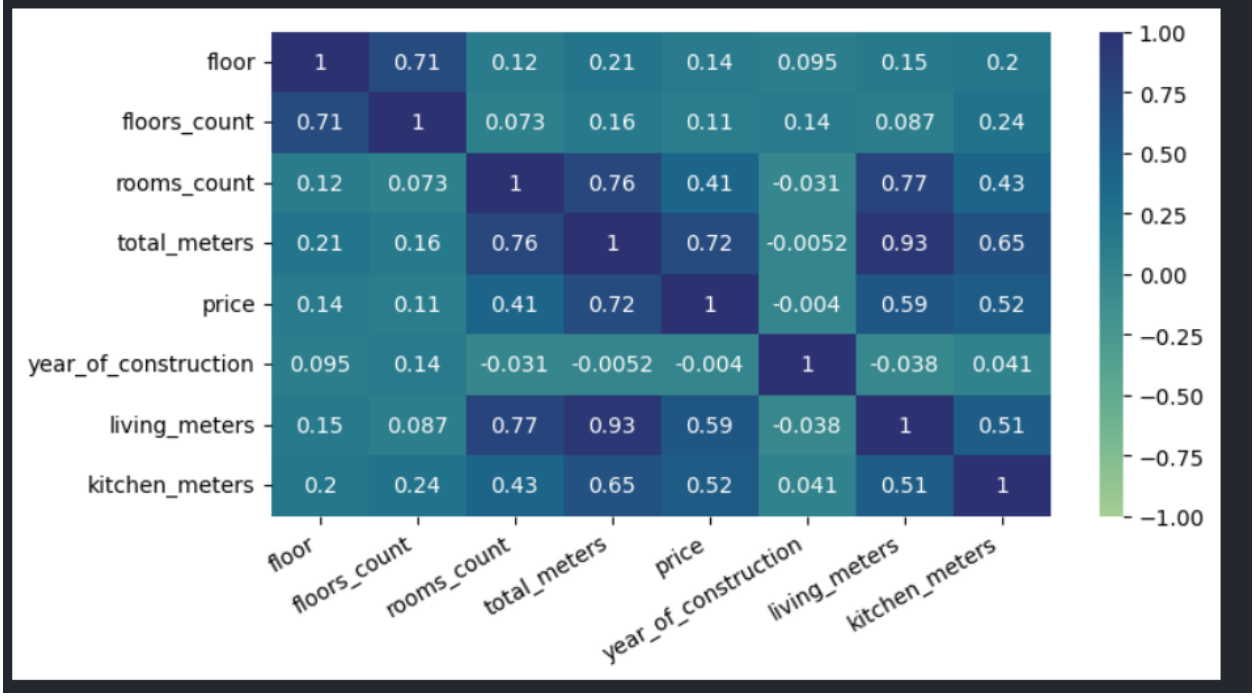

(рис.4)

```python
# Проверка на отсутствующие данные в процентах
for col in df.columns:
    pct_missing = np.mean(df[col].isnull())
    print('{} - {}%'.format(col, round(pct_missing*100)))
```

```
url - 0%
location - 4%
floor - 0%
floors_count - 0%
rooms_count - 0%
total_meters - 0%
price - 0%
year_of_construction - 0%
house_material_type - 88%
finish_type - 84%
living_meters - 23%
kitchen_meters - 15%
district - 43%
street - 14%
house_number - 11%
underground - 37%
```

(рис.5)

```
# Проверка на отсутствующие данные в цифрах
msn.bar(df, figsize=(6,3), fontsize=10, color=(1, 0.75, 0.8))
plt.show()
```

✓ 0.2s

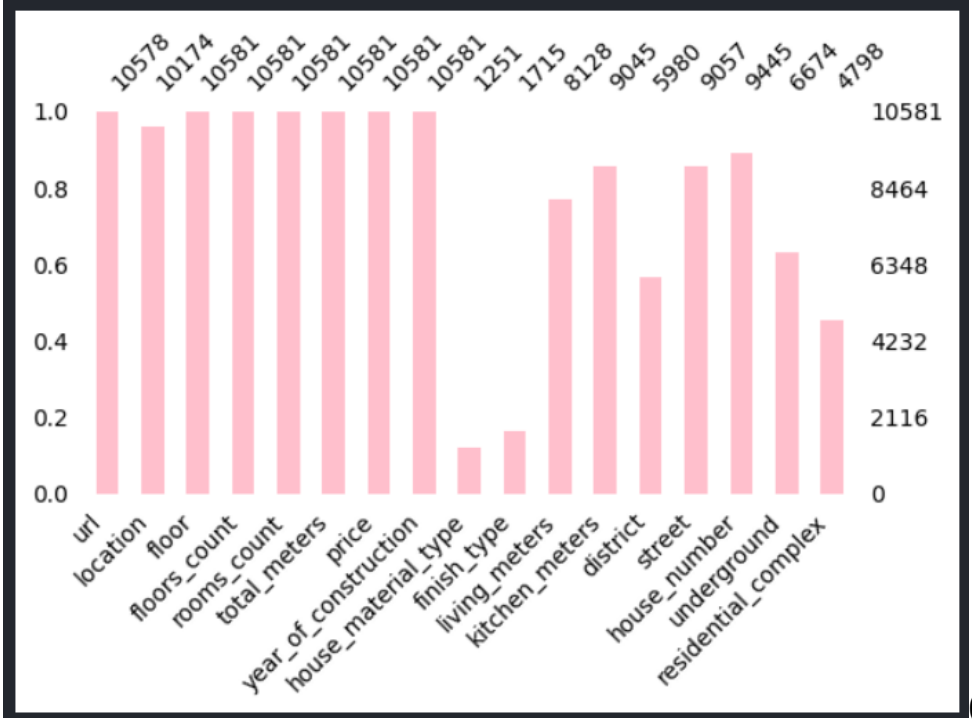

(рис.6)

```
print(df.dtypes)
df.shape
```

```
url                      object
location                 object
floor                     int32
floors_count              int32
rooms_count               int32
total_meters            float64
price                     int32
year_of_construction      int32
house_material_type      object
finish_type              object
living_meters           float64
kitchen_meters          float64
district                 object
street                   object
house_number             object
underground              object
dtype: object

(10582, 16)
```

(рис.7)

```python
df = pd.read_csv('cleaned_11K.csv')

list_of_cities = df['location'].unique()

def price_for_meter(location):
    city = df[df['location']==location]
    city_price = city['price'].sum();   cleaned_data = city['total_meters'].sum()
    return round(city_price/cleaned_data,2)

with open("dash_info_fifth.csv", 'w', newline='', encoding='UTF-8') as csvfile: # Создаем таблицу, чтобы у
    fieldnames = ['city', 'price_for_meter'];   writer = csv.DictWriter(csvfile, fieldnames=fieldnames)
    writer.writeheader()
    for city in list_of_cities: writer.writerow({'city': city, 'price_for_meter': price_for_meter(city)})
# Потом вручную удаляем строчку "nan,nan"
df = pd.read_csv('cleaned_11K.csv')

list_of_cities = df['location'].unique()

def price_for_meter(location):
    city = df[df['location']==location]
    city_price = city['price'].sum();   cleaned_data = city['total_meters'].sum()
    return round(city_price/cleaned_data,2)

with open("dash_info_fifth.csv", 'w', newline='', encoding='UTF-8') as csvfile: # Создаем таблицу, чтобы удобнее было вынимать данные
    fieldnames = ['city', 'price_for_meter'];   writer = csv.DictWriter(csvfile, fieldnames=fieldnames)
    writer.writeheader()
    for city in list_of_cities: writer.writerow({'city': city, 'price_for_meter': price_for_meter(city)})
# Потом вручную удаляем строчку "nan,nan"
```

(рис.8)

```python
df['year_of_construction'] = df['year_of_construction'].fillna(-1)
df['year_of_construction'] = df['year_of_construction'].astype(int)
df['year_of_construction'].value_counts().to_csv('years_count.csv')
```

(рис.9)

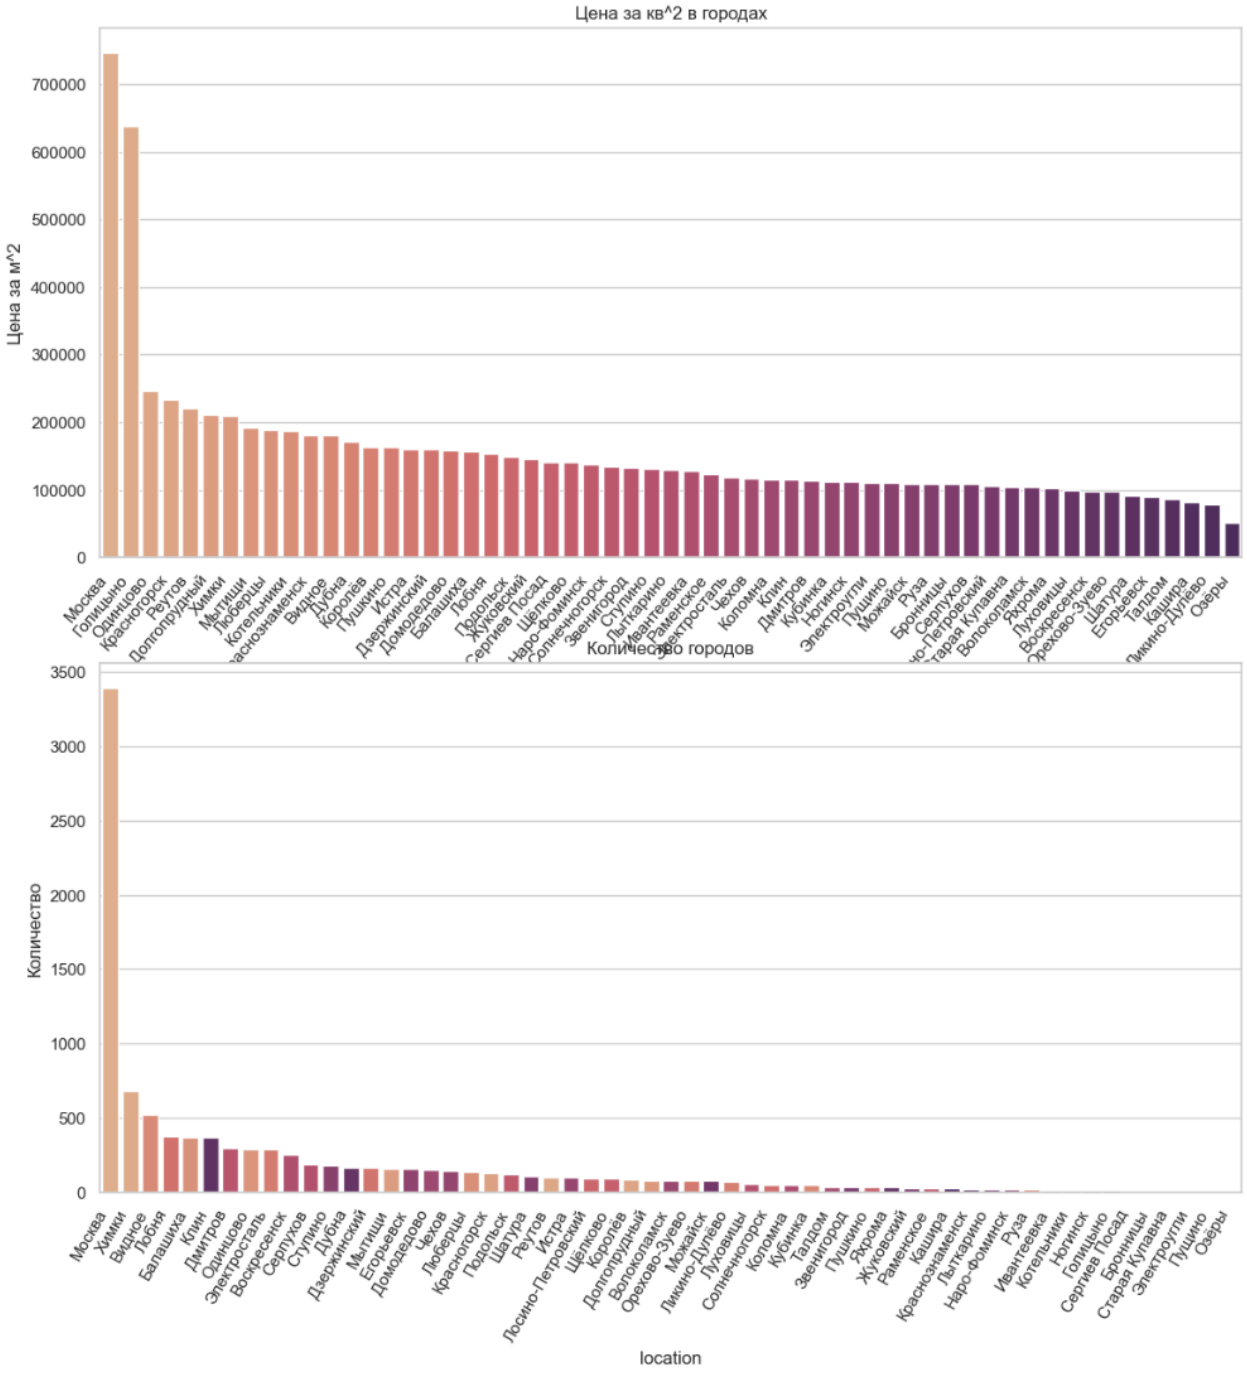
Цена за кв^2 в городах
Цена за м^2
Количество городов
Количество
location

(рис.10)

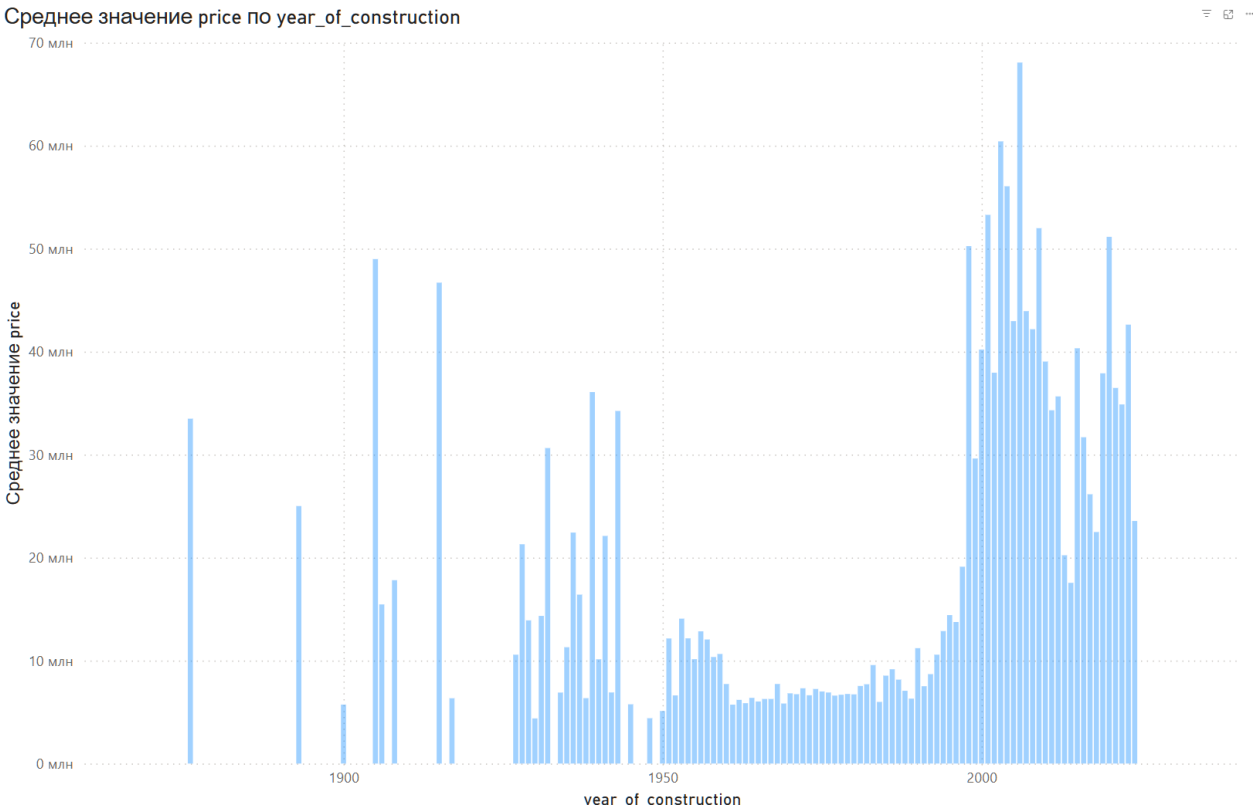
Среднее значение price по year_of_construction
70 млн
60 млн
50 млн
40 млн
30 млн
20 млн
10 млн
0 млн
Среднее значение price
1900
1950
2000
year of construction

(рис.11)

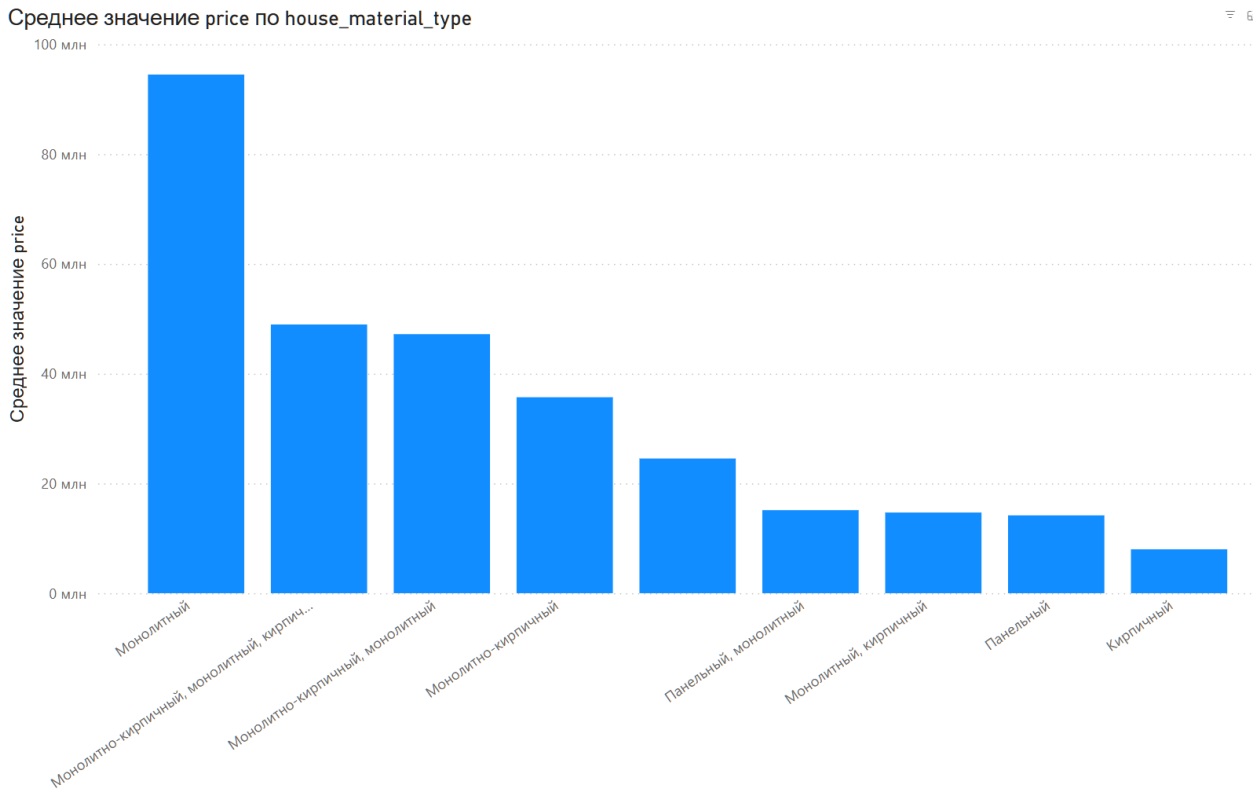
Среднее значение price по house_material_type
100 млн
80 млн
60 млн
40 млн
20 млн
0 млн
Среднее значение price
Монолитный
Монолитно-кирпичный, монолитный, кирпич...
Монолитно-кирпичный, монолитный
Монолитно-кирпичный
Панельный, монолитный
Монолитный, кирпичный
Панельный
Кирпичный

(рис.12)

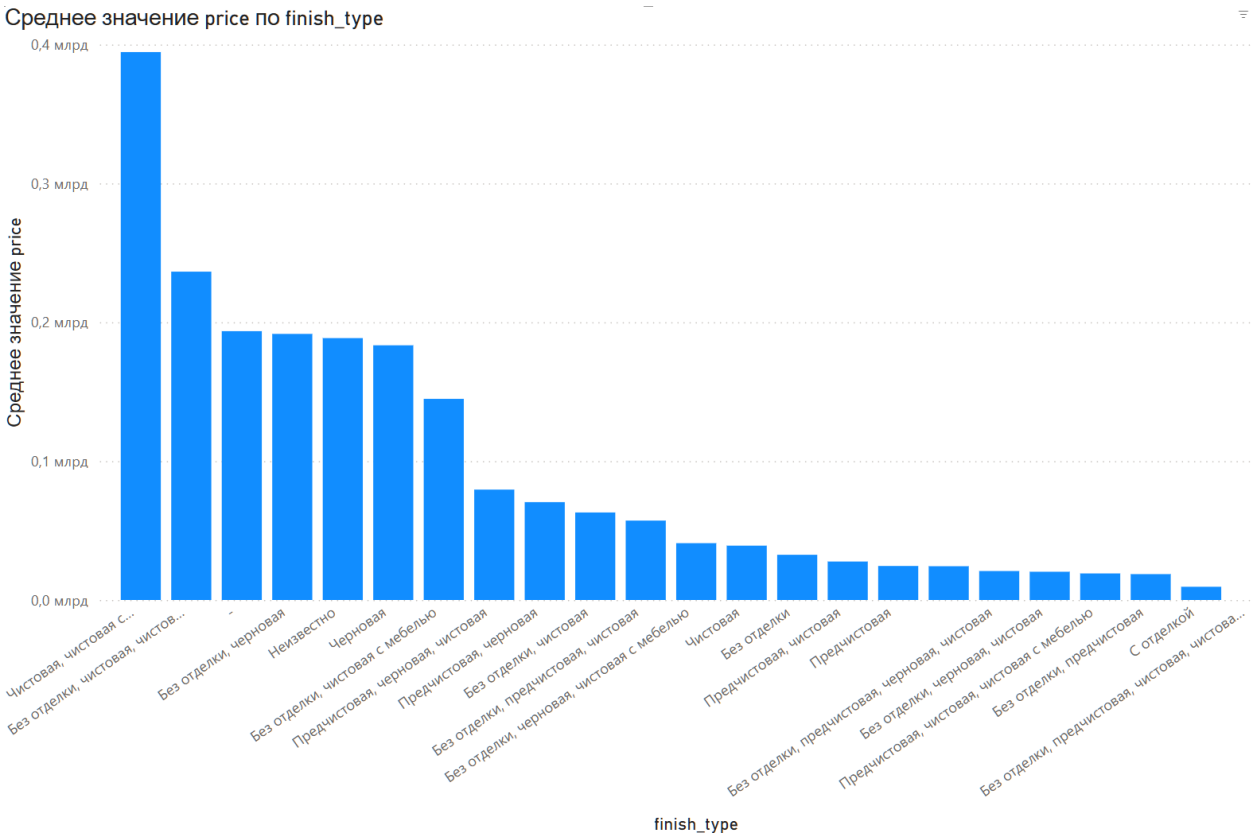
Среднее значение price по finish_type
0,4 млрд
0,3 млрд
0,2 млрд
0,1 млрд
0,0 млрд
Среднее значение price
Чистовая, чистовая с...
Без отделки, чистовая, чистов...
-
Без отделки, черновая
Неизвестно
Черновая
Без отделки, чистовая с мебелью
Предчистовая, черновая, чистовая
Предчистовая, черновая
Без отделки, черновая
Без отделки, чистовая
Без отделки, предчистовая, чистовая
Без отделки, черновая, чистовая с мебелью
Чистовая
Без отделки
Предчистовая, чистовая
Предчистовая
Без отделки, предчистовая, черновая, чистовая
Без отделки, черновая, чистовая
Предчистовая, чистовая, чистовая с мебелью
Без отделки, предчистовая
С отделкой
Без отделки, предчистовая, чистовая, чистова...
finish_type

(рис.13)